

Lab 2 - CMC-13
Criação de Classificadores baseado em Dados
CMC-13 Introdução a Ciência de Dados
(Trabalho em Grupo de dois, três ou quatro alunos)
Prof. Paulo André Castro

1. Objetivo

Exercitar e fixar conhecimentos adquiridos sobre Ciência de Dados e preparação de dados utilizando uma base de dados fornecida. *Neste trabalho, podem ser utilizados livremente frameworks para implementação dos métodos de aprendizado de máquina. Sugere-se o uso do scikit learn, mas outros também podem ser usados.*

2. Descrição do Trabalho

2.1. Base de dados (dataset)

O dataset incluem dados sobre rotatividade de clientes em serviços. A rotatividade de clientes (customer churn) refere-se ao fenômeno em que os clientes interrompem seu relacionamento ou assinatura com uma empresa ou provedor de serviços. Representa a taxa na qual os clientes param de usar os produtos ou serviços de uma empresa dentro de um período específico. A rotatividade é uma métrica importante para as empresas, pois impacta diretamente a receita, o crescimento e a retenção de clientes.

Um cliente cancelado (Churn=zero) é aquele que decidiu cancelar sua assinatura ou o uso dos serviços da empresa. Por outro lado, um cliente não cancelado (churn=1) é aquele que continua engajado e mantém seu relacionamento com a empresa. O dataset está disponibilizado com os seguintes atributos.

CustomerID= (número inteiro), Age= (número inteiro), Gender= (Male/Female), Tenure= (número inteiro), Usage Frequency= (número inteiro) e outros atributos: ,Support Calls, Payment Delay, Subscription Type, Contract Length, Total Spend, Last Interaction, Churn

Os dados podem ser inteiros, categóricos ou contínuos. A variável alvo é o cliente cancelar ou não o serviço (Churn). A preparação de dados deve verificar a existência de dados faltantes ou inconsistentes e definir como trata-los (se houver). Deve-se também avaliar a relevância de cada campo para a realização de uma melhor estimativa de rotatividade de cliente.

Observe que há dois arquivos de dados (lab2_cmc13_dados_treinamento.csv, lab2_cmc13_dados_teste.csv), com mesmo formato, que devem ser usados no treinamento e teste dos modelos, respectivamente.

2.2. Tarefas a Realizar

1. Preparação dos Dados

Avalie se todos os campos são úteis para o trabalho. Se houver campos não úteis, exclua-os dando justificativa. Prepare os dados para serem apresentados aos modelos de classificação. Os dados podem ter atributos faltantes ou com imprecisões em seu valor (ruído).

2. Crie três modelos usando diferentes técnicas de aprendizado de máquina para resolver o problema.

a) Modelo baseado em K-NN, Árvore de Decisão ou SVM

Crie um modelo baseado em K-NN (K Nearest Neighbours), árvore de decisão ou SVM para fazer a estimativa da variável alvo.

b) Modelo baseado em Redes Neurais do tipo MLP (MultiLayer Perceptron)

Crie um modelo baseado em Redes Neurais do tipo MLP (MultiLayer Perceptron) para fazer a estimativa da variável alvo.

c) Modelo baseado em Comitês (Random Forests, AdamBoost, etc)

Crie um modelo baseado em Florestas Aleatórias (Random Forests) ou outra técnica vista de comitê vista (AdaBoost, XGBoost, etc) para fazer a estimativa da variável alvo.

3. Análise Comparativa do desempenho dos modelos.

Avalie comparativamente os três modelos, utilize medidas apropriadas de desempenho de modelos (acurácia, precision, recall, F1-score, Kappa statistic, etc). Discuta os resultados e qual seria o modelo mais apropriado, para um classificador automático de livros.

Verifique o desempenho nos dados de treinamento e teste. Há variação de desempenho significativa? Em caso positivo, explique porquê.

3. Material a ser Entregue e Prazo

Devem ser entregues um relatório e um notebook com o código

Entregar através do Google Classroom!

OBS: Não compacte os arquivos em um zip (ou qq outro formato), faça os uploads dos dois arquivos!

A. Relatório em formato pdf (ver detalhes abaixo)

B. Código em formato Notebook (ve detalhes abaixo)

Prazo de Entrega: 25/junho/2026;

Item A: Relatório

Estrutura do Relatório do Projeto (arquivo em formato pdf)

Título: Lab. 2 - Criação de Classificadores baseado em Dados

Equipe: Nomes do membros da Equipe

1. Preparação dos dados

Descrever procedimentos realizados para concluir esta tarefa

2. Criação dos Modelos de Classificação

Descrever procedimentos realizados para concluir esta tarefa

3. Análise Comparativa do desempenho dos modelos.

Apresente os dados e discussões sobre os resultados, inclusive dados sobre o desempenho no dataset de treino e testes.

4. Conclusões, Comentários e Sugestões sobre o Trabalho

Item B: Código do Projeto

Código do Projeto (Formato jupyter notebook, Linguagem: Python , R ou Julia)

Siga a estrutura do relatório, para organizar o código no notebook

Preparação dos dados

Códigos correspondentes

Criação dos Modelos de Classificação

Códigos correspondentes

Análise Comparativa do desempenho dos modelos.

Códigos correspondentes

Obs:

Use células markdown antes de cada célula de código, para descrever qual o propósito do código em seguida

Bom Trabalho!
Prof. Paulo André Castro